

AIO Conquer 2026 – Module 01 – Phase 1 Review

Rà soát thiết kế dữ liệu & đánh giá cho hybrid-RAG (BM25 + kNN + RRF + bge-reranker → Qwen3-8B)

Team: AIO_2026 – Med_Pharm_Bio_Nexus

Deadline thực nghiệm: 22–25 tháng 06 năm 2026

Q0. Định vị nghiên cứu — Tính mới & Ý nghĩa khoa học

Q0.1. Kết luận thẳng thắn (VERDICT)

Đây **KHÔNG** phải là một bước đột phá (breakthrough) ở tầm hội nghị/tạp chí hàng đầu. Nhóm không nên tuyên bố novelty top-tier. Tuy nhiên, dự án vẫn **có incremental novelty và có giá trị khoa học/giáo dục thật sự**. Quan điểm trung thực này phải được giữ xuyên suốt báo cáo và thảo luận.

Q0.2. "Cùng dataset ≠ không có gì mới"

Dataset chỉ là một biến trong nhiều biến (LLM backbone, kiến trúc retrieval, embedding, reranker, evaluation protocol). GPT-RagAD (Liu et al., 2025) sử dụng Mayo Clinic + Symptom2Disease nhưng với kiến trúc khác hẳn hệ thống của team. Bảng dưới đây làm rõ điểm này.

Khía cạnh	GPT-RagAD (Liu et al., 2025)	Hệ thống của team (Technical Proposal)
LLM backbone	Theo bài báo, mục 4.4 (p. 6), tác giả đánh giá với LLaMA3, GPT-3.5 và GPT-4o. ⚠️ UNVERIFIED: trong mã nguồn release (<code>`first_layer_graph_gen.py`</code> & <code>`second_layer_gpt_rerank.py`</code> của repo <code>`tracy3057/GPT-RagAD`</code>), tham số được hard-code là <code>`ChatOpenAI(model="gpt-4")`</code> — đây là sự không khớp giữa paper và code released.	Qwen3-8B, open-source, có thể chạy local [Technical Proposal, §8.1].
Retrieval	Hai lớp: (1) lớp 1 — Heterogeneous Information Network + VGAE để chọn 100 candidate (paper §3.1, p. 3–4; Appendix A.4, p. 11); (2) lớp 2 — LLM re-ranking với prompt Vanilla / CoT / Auto-CoT (paper §3.2, p. 4–5).	Hybrid BM25 + kNN(BGE-small) + RRF (top-20) → bge-reranker-base (top-5) → Qwen3-8B [Technical Proposal, §2 & §6].
Embedding	Paper §3.1 (p. 4) mô tả dùng BERT embedding similarity (BERT similarity ≥ τ) cho symptom–symptom edges. Tuy nhiên, code released sử dụng <code>`SentenceTransformer("all-MiniLM-L6-v2")`</code> (hàm <code>`disease_graph_gen`</code> và <code>`mayo_disease_graph_gen`</code> trong <code>`first_layer_graph_gen.py`</code>).	BGE-small-en-v1.5, 384-dim, L2-normalized, cosine similarity [Technical Proposal, §4.1–4.2].
Knowledge representation	Multi-relational KG: disease–symptom (Eds), symptom–symptom (Esym), disease–disease (Edd, Jaccard ≥ γ); embedding học bằng VGAE với reconstruction loss (paper §3.1, p. 5).	Mỗi disease là một document duy nhất với 3

Khía cạnh	GPT-RagAD (Liu et al., 2025)	Hệ thống của team (Technical Proposal)
		logical views: embedded_text (symptom-first), keyword_text (BM25), metadata (severity, description, precautions) [Technical Proposal, §3.1].
Reproducibility (released code)	Theo gitingest của `tracy3057/GPT-RagAD`: (1) KHÔNG có code huấn luyện VGAE — chỉ có file embedding tiền-tính `processed_data/Symptom2Disease/mayo_node_embeddings_disease.npy`; (2) toàn bộ path bị hard-code (`./processed_data/Symptom2Disease/...`); (3) script chỉ chạy được pipeline Symptom2Disease ở top-level (không có script tự động cho DX, IMCS21); (4) `requirement.txt` (singular) trong khi README ghi `requirements.txt`.	Toàn bộ pipeline tự chứa trên Aiven OpenSearch (managed) + ứng dụng client (BGE embedding, bge-reranker, Qwen3-8B) [Technical Proposal, §5–8].

Lưu ý phương pháp luận: Mọi nhận xét "khả năng reproducibility của GPT-RagAD" trong báo cáo này đều được trích dẫn đến đường dẫn file cụ thể trong file gitingest (`tracy3057/GPT-RagAD`). Mọi điểm không thấy bằng chứng đều được đánh dấu ⚠ UNVERIFIED và không được suy đoán.

Q0.3. Bốn lớp giá trị thực tế (Four value layers)

Dự án được định vị là một "replication + ablation study with an open-source stack", với bốn lớp giá trị có thể bảo vệ được:

- **(1) Reproducibility** — Số liệu Hit@K / NDCG@K mà GPT-RagAD công bố đạt được khi backbone là GPT-4o (Liu et al., 2025, paper §4.4, p. 6). Câu hỏi của team: khi thay backbone bằng một LLM open-source chạy local (Qwen3-8B) và đổi sang một kiến trúc retrieval đơn giản hơn (hybrid BM25 + kNN + RRF + reranker thay cho VGAE-KG), kết quả còn giữ được ở mức nào? Đây là câu hỏi reproducibility hợp lệ về mặt khoa học.
- **(2) Systematic ablation** — GPT-RagAD công bố ablation "1st-layer only vs full 2-layer" (paper Table 5, p. 12) và ablation theo candidate size (Table 8, p. 14), nhưng không cung cấp ablation chi tiết theo trục retrieval. Team có thể đóng góp một ablation đầy đủ: BM25-only / kNN-only / Hybrid (BM25 + kNN + RRF) / Hybrid + bge-reranker. Đây là mặt cắt mà GPT-RagAD bỏ ngỏ.
- **(3) Practical cost / accessibility** — Toàn bộ stack chạy được trên Aiven free tier (single-node OpenSearch, 4 GB RAM, 20 GB storage) [Technical Proposal, §5] + Colab free + LLM open-source local; không cần API trả phí. Đây là engineering value rõ ràng, phù hợp với bối cảnh học thuật nguồn lực hạn chế.

- **(4) Giá trị giáo dục** — Làm chủ trọn bộ vòng đời medical-RAG (data → normalization → indexing → hybrid retrieval → reranking → LLM → evaluation), bao gồm honest evaluation (báo cáo cả mạnh lẫn yếu, có confidence interval và ablation đúng quy chuẩn). Đây là mục tiêu cốt lõi của một dự án Module 01.

Q0.4. Giới hạn — phải tuyên bố công khai

- Không có benchmark mới, không có dataset mới, không có architecture mới ở mức nguyên thủy → không phải "novel contribution" theo nghĩa top-tier.
- Symptom2Disease chỉ có 24 disease classes và 1,200 sample tổng (Barman, n.d.) → kết quả mang tính pilot/illustrative, độ phủ rất hẹp so với 1,058 disease của Mayo Clinic KB hoặc 49 pathology của DDXPlus.
- So sánh trực tiếp số liệu Hit@K / NDCG@K của team với số liệu công bố trong Table 1 của GPT-RagAD (Liu et al., 2025, p. 7) phải được trình bày như một REFERENCE POINT, KHÔNG phải one-to-one baseline — vì khác cả architecture, embedding, LLM backbone, và có thể khác subset của Symptom2Disease (paper chọn ngẫu nhiên 500/1,200; xem Q5.1).

Q0.5. Phase 2 — Nơi sự khác biệt thực sự xuất hiện (DDXPlus)

GPT-RagAD KHÔNG sử dụng DDXPlus (Liu et al., 2025, paper §4.1, p. 6 — chỉ DX, IMCS21, Symptom2Disease). MedRAG (Zhao et al., 2025) có dùng DDXPlus + CPDD, nhưng với một KG bốn tầng (four-tier hierarchical KG) khá nặng và Mini-CEX subjective evaluation.

→ Một light hybrid-RAG (không cần KG) đánh giá trên DDXPlus với các metric ICD-10 hierarchical near-miss và severity-aware safety là một góc tiếp cận **chưa được khai thác đầy đủ** trong cả hai bài. Các trường *icd10-id* và *severity* (release_conditions.json — Tchango et al., 2022) cùng *DIFFERENTIAL_DIAGNOSIS* (patient CSV) cho phép định nghĩa các metric an toàn lâm sàng (clinical-safety-aware) một cách tự nhiên. Đây là nơi incremental novelty rõ nét nhất — nhưng dành cho Phase 2, KHÔNG phải Phase 1.

Q0.6. Kết luận định vị

Breakthrough = No (không tuyên bố). Incremental novelty = Yes. **Significance** = (i) independent replication trên một stack rẻ và open-source, (ii) end-to-end mastery của một medical-RAG pipeline, (iii) honest evaluation. Việc GPT-RagAD đã dùng cùng hai dataset là một **LỢI THẾ** — cung cấp public reference point để team đặt số liệu của mình bên cạnh.

Q1. Xác minh dataset từ nguồn sơ cấp

Q1.1. Mayo Clinic Symptoms and Diseases (HF: celikmus/mayo_clinic_symptoms_and_diseases_v1)

- **Nguồn:** huggingface.co/datasets/celikmus/mayo_clinic_symptoms_and_diseases_v1 [URL trong tham chiếu của paper GPT-RagAD, footnote 2 trang 6 và footnote 3 trang 11].
- **Schema (xác minh trực tiếp trên trang HF dataset card):** hai cột — `text` (stringlengths 59–18.7k) và `label` (stringlengths 3–40). Chỉ một split: `train` (1.06k rows).
- **Số bệnh:** 1,058 disease theo paper GPT-RagAD (paper §4.1, p. 6 và Appendix A.1, p. 11). Trang HF hiển thị "1.06k rows" — phù hợp với 1,058 sau làm tròn. Không tách được trên trang HF vì chỉ hiển thị ≈ 1,060.
- **License:**  UNVERIFIED — Trang dataset card của Hugging Face cho `celikmus/mayo\_clinic\_symptoms\_and\_diseases\_v1` không hiển thị license tag rõ ràng tại thời điểm kiểm tra. Team cần xác nhận lại trước khi public hóa code/data. Dữ liệu gốc của Mayo Clinic chịu các điều khoản sử dụng của Mayo Clinic về "personal, non-commercial use" — team chỉ nên sử dụng cho mục đích nghiên cứu/giáo dục và KHÔNG redistribute trực tiếp.
- **DUA:** Không có DUA riêng cho dataset này trên Hugging Face (không gated).

- **Ghi chú quan trọng cho team:** Format raw của Mayo Clinic chỉ có (text, label) — KHÔNG có sẵn các trường `symptoms`, `severity`, `description`, `precautions` mà Technical Proposal §3 mô tả. Để có schema này, team cần (a) trích xuất danh sách symptom từ field `text` bằng LLM (chính là cách GPT-RagAD làm, xem hàm `mayo\_symptom\_generate` trong `first\_layer\_graph\_gen.py`), hoặc (b) hợp nhất Mayo với một nguồn khác cung cấp severity & precautions. Đây là một đặc điểm cần làm rõ và lên kế hoạch ETL ngay từ Day 1.

Q1.2. DDXPlus (Mila-Quebec AI Institute)

- **Nguồn chính thức:** GitHub `mila-iqia/ddxplus` (<https://github.com/mila-iqia/ddxplus>) — bản English; figshare DOI: https://figshare.com/articles/dataset/DDXPlus_Dataset_English_/22687585.
- **Bài báo gốc:** Tchango, A. F., Goel, R., Wen, Z., Martel, J., and Ghosn, J. (2022). DDXPlus: A New Dataset For Automatic Medical Diagnosis. NeurIPS 2022 Track on Datasets and Benchmarks. arXiv:2205.09148.
- **License:** CC-BY (Tchango et al., 2022, §3.4, p. 6: "we generate, under the CC-BY licence, a dataset of roughly 1.3 million patients"). Mirror HF `aai530-group6/ddxplus` ghi `cc-by-4.0` cụ thể, tuy nhiên team nên trích figshare official posting (license: CC-BY) là nguồn primary.
- **Tính chất:** FULLY SYNTHETIC — được sinh bằng một proprietary medical knowledge base + một commercial rule-based AD system; KHÔNG chứa dữ liệu thật của bệnh nhân (Tchango et al., 2022, §3, p. 3–6).

release_conditions.json — schema (xác minh từ Tchango et al., 2022 & README mila-iqia/ddxplus)

Trường	Mô tả (trích nguyên văn từ nguồn)
condition_name	Tên bệnh dạng raw (tiếng Pháp ở bản FR).
cond-name-fr	Tên bệnh tiếng Pháp.
cond-name-eng	Tên bệnh tiếng Anh — "In the English version, the English name is used instead of the French name" (mila-iqia/ddxplus README).
icd10-id	Mã ICD-10 của bệnh (ví dụ: "G70.0" cho Myasthenia gravis — README mila-iqia/ddxplus, JSON snippet).
severity	Tchango et al. (2022, §3.1, p. 4): "each disease is characterized by its level of severity ranging from 1 to 5 with the lowest values describing the most severe pathologies." Tức là 1 = nặng nhất, 5 = nhẹ nhất.
symptoms	Dictionary mô tả các symptom đặc trưng của bệnh; mỗi symptom được tham chiếu qua `name` trong release_evidences.json (README mila-iqia/ddxplus).
antecedents	Dictionary các antecedent (tiền sử) đặc trưng; cũng tham chiếu qua `name` trong release_evidences.json.

Patient CSV — schema (xác minh từ Tchango et al., 2022 & HF mirror `aai530-group6/ddxplus`)

Trường	Mô tả (trích nguyên văn)
AGE	Tuổi của patient synthetic.
SEX	Giới tính.
PATHOLOGY	Ground-truth disease — dùng để tính accuracy.

Trường	Mô tả (trích nguyên văn)
EVIDENCES	List of evidences experienced by the patient. "An evidence can either be binary, categorical or multi-choice." Mã hoá: [evidence-name]_@[evidence-value] cho categorical / multi-choice; [evidence-name] cho binary. "For a multi-choice evidence, it is possible to have several [evidence-name]_@[evidence-value] items in the evidence list, with each item being associated with a different evidence value" (HF aai530-group6/ddxplus README, Tchang et al., 2022 §1.1).
INITIAL_EVIDENCE	Theo HF mirror aai530-group6/ddxplus và README mila-iqia/ddxplus: "the evidence provided by the patient to kick-start an interaction with an ASD/AD system. This is useful during model evaluation for a fair comparison of ASD/AD systems as they will all begin an interaction with a given patient from the same starting point." ⚠️ UNVERIFIED: README không nói rõ cơ chế chọn INITIAL_EVIDENCE; KHÔNG có khẳng định "randomly selected" trong README chính thức của mila-iqia/ddxplus. Team không nên giả định cơ chế chọn cụ thể.
DIFFERENTIAL_DIAGNOSIS	Differential diagnosis dạng (pathology, normalized score), đã chuẩn hoá thành distribution. Sinh ra bởi commercial rule-based AD system (Tchang et al., 2022 §3.3, p. 5).

Split chính thức (Tchang et al., 2022, §3.4, p. 6)

- Tỷ lệ split: 80% / 10% / 10% cho train / validate / test, dùng stratified sampling trên simulated pathology. Trích nguyên văn: "We divide the dataset into training, validation, and test subsets based on an 80%-10%-10% split, using stratified sampling on the simulated pathology."
- Tổng quy mô: "roughly 1.3 million patients" (Tchang et al., 2022, §3.4, p. 6). Phân bố cụ thể của 49 pathology: xem Figure 2, p. 7 — có 3 pathology trội (URTI, Viral pharyngitis, Anemia).
- Số liệu thống kê evidence (Tchang et al., 2022, Table 2, p. 7): trung bình 13.56 evidence/patient (10.07 symptom + 3.49 antecedent); std=5.06.
- 49 pathology; 110 symptom + 113 antecedent = 223 evidence types (Tchang et al., 2022, Table 1, p. 7).

Q1.3. Symptom2Disease (Kaggle: niyarbarman/symptom2disease)

- **Nguồn:** <https://www.kaggle.com/datasets/niyarbarman/symptom2disease> (Barman, n.d.).
- **Schema:** 1,200 datapoint, 2 cột — `label` (disease name) và `text` (natural language symptom description). 24 disease × 50 symptom description / disease = 1,200 datapoint (Barman, n.d. — Kaggle dataset card: "24 different diseases, and each disease has 50 symptom descriptions, resulting in a total of 1200 datapoints").
- **Train/test split:** Theo trang Kaggle, chỉ có một file CSV duy nhất (Symptom2Disease.csv) — KHÔNG có official train/test split. Team PHẢI tự thiết kế stratified split. Trong báo cáo cuối, cần ghi rõ "no official split exists; we designed a stratified 70/15/15 split (or similar) ourselves with seed=42".
- **License:** ⚠️ UNVERIFIED — Trang Kaggle không hiển thị license rõ ràng tại thời điểm web crawl. Team nên kiểm tra lại license tag trên Kaggle UI trước khi commit code lên GitHub public.
- **Tính chất (synthetic vs real):** ⚠️ UNVERIFIED — Trang Kaggle không nêu rõ cách thức sinh dữ liệu (không nói human-written hay LLM-generated). Một số bản fork trên Hugging Face (vd `gretelai/symptom\_to\_diagnosis`) ghi rõ "adapted... using an LLM" cho phiên bản của họ, nhưng đây là phái sinh, không phải bản gốc. Team KHÔNG nên khẳng định "semi-synthetic" mà phải đánh dấu ⚠️ UNVERIFIED.

- **24 disease classes (Barman, n.d.):** Psoriasis, Varicose Veins, Typhoid, Chicken pox, Impetigo, Dengue, Fungal infection, Common Cold, Pneumonia, Dimorphic Hemorrhoids, Arthritis, Acne, Bronchial Asthma, Hypertension, Migraine, Cervical spondylosis, Jaundice, Malaria, urinary tract infection, allergy, gastroesophageal reflux disease, drug reaction, peptic ulcer disease, diabetes.

Q1.4. CPDD (Chronic Pain Diagnostic Dataset — Tan Tock Seng Hospital)

- **Nguồn:** Private — collected from Tan Tock Seng Hospital, Singapore. Đề cập trong MedRAG (Zhao et al., 2025, §5.1, p. 6 và Appendix B.1, p. 11).
- **Quy mô:** 551 patients, 33 distinct diagnoses (Zhao et al., 2025, §5.1, p. 6).
- **Split:** 9:1 ratio — train (to be retrieved) / test (Zhao et al., 2025, Appendix B.2, p. 11).
- **Truy cập:** KHÔNG khả dụng public. Team KHÔNG thể truy cập trong khung thời gian dự án Phase 1.

Q1.5. MIMIC-IV (PhysioNet)

- **Nguồn:** PhysioNet — yêu cầu credentialed access (Johnson et al., 2023, MIMIC-IV PhysioNet).
- **Yêu cầu access:** (i) đăng ký tài khoản PhysioNet; (ii) hoàn thành CITI training (Human Subjects/Data or Specimens Only Research); (iii) ký Data Use Agreement v1.5.0.
- **Tương tác với cloud LLM API:** PhysioNet Credentialed Health Data Use Agreement v1.5.0 cấm chia sẻ dữ liệu với bên thứ ba. Theo policy chính thức của PhysioNet (<https://physionet.org/news/post/gpt-responsible-use/> và <https://physionet.org/news/post/llm-responsible-use/>): "The PhysioNet Credentialed Data Use Agreement explicitly prohibits sharing access to the data with third parties, including sending it through APIs provided by companies like OpenAI, or using it in online platforms like ChatGPT." Khuyến nghị của PhysioNet: ưu tiên LLM chạy local; nếu dùng cloud API thì phải ZERO data retention (vd Azure OpenAI với opt-out human review).
- **Kết luận khả thi với Phase 1:** MIMIC-IV KHÔNG khả thi cho deadline 22–25/06. Riêng credentialing + CITI training thường mất nhiều tuần. KHÔNG dùng MIMIC-IV trong Phase 1.

Q2. Kiểm tra trung thực Synthetic vs Real + Tính khả thi truy cập

Bảng dưới đây phân loại 5 dataset theo (i) spectrum synthetic/real và (ii) khả năng dùng được trong khung thời gian 22–25 tháng 06 năm 2026. Mọi phân loại không được tài liệu hoá rõ ràng đều được đánh dấu ⚠️ UNVERIFIED.

Dataset	Provenance	License / DUA	Cloud LLM API permitted?	Khả thi cho Phase 1 (22–25/06)
DDXPlus	FULLY SYNTHETIC — sinh từ proprietary KB + commercial rule-based AD system (Tchango et al., 2022, §3, p. 3–6).	CC-BY (Tchango et al., 2022, §3.4, p. 6).	Có — fully synthetic, không có patient thật.	✅ KHẢ THI — download free từ figshare/mila-iqia. Tuy nhiên quy mô lớn (~1.3M patient), nên team cần sample subset như cách MedRAG làm (Zhao et al., 2025, Appendix B.2: 13,230 patient max-balanced).

Dataset	Provenance	License / DUA	Cloud LLM API permitted?	Khả thi cho Phase 1 (22–25/06)
Mayo Clinic (celikmus)	Curated TEXT từ public knowledge base của Mayo Clinic (paper GPT-RagAD §4.1, p. 6). Không phải patient data — chỉ là disease description.	⚠️ UNVERIFIED — HF dataset card không hiển thị license tag rõ ràng. Mayo Clinic gốc có ToS "personal, non-commercial use".	Có (về mặt kỹ thuật, vì không phải patient data); nhưng team không nên redistribute nội dung gốc Mayo.	✅ KHẢ THI — load qua HF Datasets library: <code>`load_dataset("celikmus/mayo_clinic_symptoms_and_diseases_v1")`</code> .
Symptom2Disease (Kaggle niyarrbarman)	⚠️ UNVERIFIED — Trang Kaggle không nói rõ human-written hay LLM-generated. KHÔNG nên đoán là "semi-synthetic".	⚠️ UNVERIFIED — Trang Kaggle không hiển thị license rõ ràng tại thời điểm crawl. Team cần kiểm tra lại trên Kaggle UI.	Có (về mặt kỹ thuật) — không phải credentialed data.	✅ KHẢ THI — download free từ Kaggle (cần Kaggle account).
CPDD	REAL — EHR thật từ Tan Tock Seng Hospital, focus vào chronic pain (Zhao et al., 2025, §5.1, p. 6).	PRIVATE — không public release; chỉ truy cập qua collaboration với NTU/TTS H.	Không (private EHR).	❌ KHÔNG KHẢ THI — không khả dụng public.
MIMIC-IV	REAL — de-identified ICU EHR	PhysioNet Credentialed Health Data Use	PhysioNet policy chính thức	❌ KHÔNG KHẢ THI — chỉ riêng credentialing + CITI training đã mất nhiều tuần.

Dataset	Provenance	License / DUA	Cloud LLM API permitted?	Khả thi cho Phase 1 (22–25/06)
	từ Beth Israel Deaconess Medical Center (PhysioNet credentialled).	Agreement v1.5.0 — yêu cầu CITI training + DUA signing.	(gpt-responsible-use, llm-responsible-use) cấm gửi MIMIC qua API của bên thứ ba. Khuyến nghị LLM chạy local (như Qwen3-8B trong Technical Proposal §8.1 là phù hợp); nếu dùng cloud thì phải zero data retention.	

Kết luận Q2: Trong 5 dataset, chỉ DDXPlus, Mayo Clinic, và Symptom2Disease khả thi cho Phase 1. CPDD và MIMIC-IV bị loại do truy cập. Việc team chỉ dùng dataset public và synthetic/non-patient data ở Phase 1 là phù hợp với chuẩn mực đạo đức nghiên cứu cho một dự án Module 01.

Q3. So sánh khả thi 3 phương án thiết kế (kiến trúc cố định theo Technical Proposal)

Kiến trúc cố định: OpenSearch hybrid BM25 + kNN(BGE-small-en-v1.5, 384-dim) + RRF → top-20 → bge-reranker-base → top-5 → Qwen3-8B [Technical Proposal, §2, §6, §8]. Phần này chỉ tư vấn về dataset choice + evaluation, KHÔNG đề xuất thay đổi kiến trúc.

Q3.1. Định nghĩa ba phương án

- **Design A — DDXPlus-centric (single label space):** Dùng DDXPlus cho cả Knowledge Base (KB) lẫn query (patient records). Đây là một ADAPTATION của setup MedRAG (Zhao et al., 2025, §5.1, p. 6: DDXPlus + CPDD), KHÔNG phải replication thực sự — vì MedRAG dùng KG 4-tầng còn team dùng light hybrid-RAG.
- **Design B — Mayo KB + DDXPlus queries:** Mayo (1,058 disease) làm KB, DDXPlus patient records làm query set. KHÔNG phải setup nguyên bản của BẤT KỲ paper nào — đây là một mash-up. Cần ICD-10/disease-name mapping giữa hai vũ trụ label, là phần phức tạp nhất.

- **Design C — Mayo KB + Symptom2Disease queries:** Mayo (1,058 disease) làm KB, Symptom2Disease (24 disease, 1,200 sample) làm query set. Đây CHÍNH LÀ setup mà GPT-RagAD theo sát nhất (Liu et al., 2025, §4.1, p. 6: Mayo Clinic KB + Symptom2Disease 500/1,200 sample). Là phương án bám sát methodology Paper 1 nhất.

Q3.2. Bảng so sánh chi tiết

Tiêu chí	Design A (DDXPlus only)	Design B (Mayo KB + DDXPlus query)	Design C (Mayo KB + S2D query)
(a) Khả thi trên Aiven free (4 GB RAM, 20 GB) + Colab free trong 22–25/06	MEDIUM — DDXPlus có 49 condition (release_conditions.json) làm KB là nhẹ; nhưng full 1.3M patient records là quá lớn, phải subsample như MedRAG (Zhao et al., 2025, Appendix B.2: 13,230 patient max-balanced). Index 49 KB doc + 13k query embedding: vừa với free tier nếu chỉ embed query khi inference.	MEDIUM-HIGH — KB Mayo có 1,058 doc → embedding store < 5 MB (1,058 × 384 dim × 4 byte ≈ 1.6 MB), thừa sức free tier. Query side cũng là DDXPlus subsample. Bottleneck duy nhất: label-mapping (ICD-10) — TIME-INTENSIVE.	HIGH — KB Mayo 1,058 doc + query S2D 1,200 sample. Mọi thứ vừa thoải mái free tier. Đây là phương án nhẹ nhất.
(b) Tính giá trị khoa học	MEDIUM — chỉ là ADAPTATION của MedRAG (architecture khác hẳn, không phải replication). Lợi thế: có thể đánh giá ICD-10 hierarchical metric và severity-aware safety (tận dụng đầy đủ trường icd10-id, severity, DIFFERENTIAL_DIAGNOSIS của DDXPlus).	MEDIUM-LOW — KHÔNG phải setup nguyên bản của BẤT KỲ paper nào. Phần label-mapping phức tạp dễ trở thành noise lớn, làm yếu giá trị khoa học. Khó so sánh trực tiếp với baseline.	HIGH — bám sát methodology GPT-RagAD nhất; cho phép so sánh số liệu trực tiếp với Table 1 của paper (Liu et al., 2025, p. 7) như một REFERENCE POINT. Reproducibility test có giá trị thực sự.
(c) Effort (person-days)	≈ 10–12 person-days — phải hiểu encoding EVIDENCES (B/C/M), parse INITIAL_EVIDENCE và DIFFERENTIAL_DIAGNOSIS, viết template natural-language hoá patient để query. Severity / ICD-10 metric cần code thêm.	≈ 12–15 person-days — toàn bộ effort của Design A + chuẩn hoá ontology (49 DDXPlus pathology ↔ Mayo disease names). Mapping này rất dễ leak hoặc miss-align. Rủi ro cao.	≈ 6–8 person-days — không cần ICD-10 mapping. Chỉ cần map S2D label (24 disease) ↔ Mayo disease list (1,058). Vài label như "Common Cold", "Pneumonia", "Migraine" gần như 1-1. Một số label hệ thống đặt tên khác (vd "urinary tract infection" vs Mayo "urinary-tract-infection") cần normalization nhẹ.
(d) Độ phức tạp ontology / label-alignment	LOW — single label space (49 DDXPlus pathology với icd10-id sẵn).	VERY HIGH — phải mapping 49 DDXPlus pathology ↔ subset Mayo (1,058 disease). KHÔNG có mapping chính thức. Phải làm thủ công, có rủi ro mismatch lớn vì label-set của DDXPlus và Mayo không trùng nhau hoàn toàn	LOW-MEDIUM — 24 S2D label vs 1,058 Mayo label. Đa số map được; một số cần normalization (đổi snake_case ↔ Title Case).

Tiêu chí	Design A (DDXPlus only)	Design B (Mayo KB + DDXPlus query)	Design C (Mayo KB + S2D query)
		(vd DDXPlus có "URTI", "Possible NSTEMI / STEMI" trong khi Mayo dùng tên bệnh chuẩn).	
(e) Rủi ro evaluation invalidity	MEDIUM — DDXPlus có DIFFERENTIAL_DIAGNOSIS làm ground truth cho ranking, rất phù hợp với Hit@K / NDCG@K. Rủi ro: nếu pathology mapping hoặc EVIDENCES encoding sai → toàn bộ số liệu sụp.	HIGH — sai mapping label → false negative (đúng bệnh nhưng tên trong KB khác). Khó tách lỗi mapping ra khỏi lỗi retrieval. KHÔNG NÊN chọn cho project học thuật ở mức Module 01.	LOW — label mapping nhỏ và transparent; có công bố tham chiếu (GPT-RagAD Table 1). Dễ debug khi có mismatch.

Q3.3. Đề xuất chính thức cho Phase 1

Khuyến nghị: Chọn **Design C — Mayo KB + Symptom2Disease queries**.

Lý do (justification có căn cứ)

- **(i) Bám sát methodology GPT-RagAD nhất:** GPT-RagAD §4.1 (p. 6) công bố chính xác setup này — Mayo Clinic KB + Symptom2Disease (random 500/1,200 sample). Việc team dùng cùng setup này cho phép so sánh số liệu một-một như một REFERENCE POINT trực tiếp.
- **(ii) Khả thi tuyệt đối trong free tier:** 1,058 doc × 384-dim float32 ≈ 1.6 MB embedding store; 1,200 query × 384-dim ≈ 1.8 MB. Tổng index < 20 MB kể cả metadata. Không có rủi ro out-of-RAM trên Aiven 4 GB.
- **(iii) Effort thấp nhất (~6–8 person-day):** Đủ thời gian để team chạy đầy đủ ablation BM25-only / kNN-only / Hybrid+RRF / Hybrid+RRF+Reranker và báo cáo CI bootstrap.
- **(iv) Rủi ro evaluation thấp nhất:** 24 label để kiểm tra; mismatch nếu có thì dễ phát hiện và sửa.
- **(v) Phase 2 vẫn có chỗ cho DDXPlus:** Sau khi pipeline đã ổn định ở Design C, team có thể mở rộng sang Design A trong Phase 2 với ICD-10 hierarchical metric và severity-aware safety — đó mới là nơi incremental novelty rõ rệt.

Tóm tắt khuyến cáo về Design B (Mayo KB + DDXPlus query)

KHÔNG chọn Design B cho Phase 1. Phương án này phức tạp về ontology mapping mà KHÔNG bám sát methodology nguyên bản của BẤT KỲ paper nào (GPT-RagAD không dùng DDXPlus; MedRAG dùng DDXPlus nhưng với KG 4-tầng, không phải Mayo KB). Effort/reward ratio quá xấu trong khung thời gian Module 01.

Q4. Thiết kế split dữ liệu và phòng chống leakage (cho Design C)

Q4.1. Tình trạng split của Symptom2Disease

Symptom2Disease (Barman, n.d.) **KHÔNG có official train/test split** — chỉ có một file CSV duy nhất chứa 1,200 datapoint. Team phải tự thiết kế split. **Trong báo cáo cuối, phải ghi rõ "no official split exists; we designed a stratified split ourselves with random_state=42"** — không được giả vờ rằng đã tồn tại split chính thức.

Q4.2. Đề xuất chiến lược sampling và split

- **Sampling:** Stratified split theo `label` (24 class). Với 50 sample/class trong dataset gốc, một split 70/15/15 cho train_kb_calibration / dev / test sẽ ra 35/7/8 sample/class. Lưu ý: 35 "train" ở đây

KHÔNG để huấn luyện retriever (vì hệ thống là zero-training RAG), mà chỉ để (a) calibrate hyperparameter (vd RRF k=60, số top-K, threshold rerank), và (b) làm prompt-tuning set nếu cần.

- **Test set không bao giờ chạm tới khi tuning:** 8 sample/class × 24 class = 192 test sample. Dev set 7/class × 24 = 168 — đủ để tinh chỉnh prompt và pipeline; KHÔNG dùng test cho đến khi mọi quyết định đã chốt.
- **Stratification key:** phải stratify theo `label` để mỗi class có đủ representation trong cả 3 split — tránh trường hợp một class hiếm rơi hết vào test.
- **Document hoá:** lưu file CSV index của 3 split (vd `splits/train\_idx.csv`, `dev\_idx.csv`, `test\_idx.csv`) cùng với commit hash của Symptom2Disease.csv trên Kaggle để bảo đảm reproducibility.

Q4.3. Cơ mẫu tối thiểu cho Hit@K & MRR với bootstrap CI

Hướng dẫn thực tiễn (KHÔNG phải formal power analysis): Với 24 class và 8 sample/class trong test ($n_{\text{test}} = 192$), bootstrap 1,000 lần resampling đủ để có một CI95% "nice-looking" trên các metric overall (Hit@1, Hit@5, Hit@10, MRR@10, NDCG@10). Tuy nhiên với per-class metric, 8 sample/class là khá nhỏ và sẽ cho CI rộng — cần báo cáo rõ điều này thay vì che giấu.

- **Reference point:** GPT-RagAD evaluate trên 500 sample của Symptom2Disease (Liu et al., 2025, §4.1, p. 6: "We randomly select 500 samples"). Lưu ý phân biệt hai phép đo để tránh mâu thuẫn với held-out test set 192 mẫu ở Q4.2: (i) Kết quả chính thức của team báo cáo trên held-out test set (192 mẫu, không dùng tới khi tuning); (ii) Riêng để "đối thoại" với GPT-RagAD, do hệ thống là zero-training RAG (không học từ dữ liệu nên không có rò rỉ train→test), team có thể chạy thêm một phép đo retrieval trên toàn bộ 1,200 sample HOẶC trên một subset 500 sample tương đương GPT-RagAD, và báo cáo riêng như một so sánh tham chiếu — KHÔNG trộn lẫn với con số test chính thức.
- **Khuyến nghị cuối:** Test trên toàn bộ 1,200 sample là khả thi với hệ thống của team (1,200 query × ~1s/query ≈ 20 phút) và cho mẫu lớn nhất. Tuy nhiên, để fair-comparison với GPT-RagAD, có thể đồng thời báo cáo phần test trên 500 sample (lấy 500 đầu hoặc seed=42 random.sample(1200, 500)).

Q4.4. Reproducibility — các bước bắt buộc

- random_state / random_seed = 42 ở mọi nơi (sklearn train_test_split, numpy.random, torch.manual_seed nếu dùng PyTorch ở client-side embedding).
- Pin version: `sentence-transformers`, `transformers`, `opensearch-py`, `pandas`, `numpy`, `torch` — ghi trong requirements.txt.
- Commit + tag Git: tag commit ngày test final (vd `v1.0-test-2026-06-25`).
- Lưu raw output: với MỖI query, lưu (i) BM25-only top-20, (ii) kNN-only top-20, (iii) Hybrid+RRF top-20, (iv) sau bge-reranker top-5, (v) LLM prediction top-1. Đây là điều kiện bắt buộc để debug và để tính lại metric về sau.
- Ghi rõ "no leakage" check: KB Mayo (1,058 disease) ĐỘC LẬP với query S2D (24 disease). 24 class S2D đều phải có trong 1,058 Mayo doc (hoặc đã được map). Nếu một query S2D có label không xuất hiện trong KB → ghi nhận "out-of-KB" và loại khỏi metric (hoặc đếm là 0).

Q4.5. Sanity check trước khi chạy test final

- Verify rằng query embedding sử dụng đúng prefix `"Represent this sentence for searching relevant passages: "` (BGE asymmetric query, theo Technical Proposal §4.2).
- Verify rằng doc embedding KHÔNG dùng prefix.
- Verify rằng `embedding` field trong OpenSearch index có `space\_type: cosinesimil` và `dimension: 384` (theo Technical Proposal §5.2).
- Verify rằng RRF pipeline `hybrid-rrf` đã tạo và attach đúng vào query với `?search\_pipeline=hybrid-rrf` (Technical Proposal §6.3).

Q5. Metric — Tier 1 (bắt buộc 22–25/06) vs Tier 2 (deferrable)

Q5.1. Tier 1 — Metric bắt buộc phải có trong báo cáo Phase 1

Q5.1.1. Retrieval metric

- **Hit@1, Hit@5, Hit@10** — tỷ lệ ground-truth disease có trong top-1/5/10 của retrieval/reranking.
- **MRR@10** — Mean Reciprocal Rank trong top-10. Phản ánh ranking quality một cách đơn giản.
- **NDCG@10** — Normalized Discounted Cumulative Gain. Cho phép so sánh trực tiếp với Table 1 của GPT-RagAD (Liu et al., 2025, p. 7).

Q5.1.2. Generation metric

- **Top-1 accuracy (đầu ra Qwen3-8B)**: tỷ lệ disease mà LLM chọn ở vị trí #1 trong câu trả lời cuối là đúng. Đây chính là metric "Hit@1" sau bước LLM (xem cách GPT-RagAD báo cáo trong Table 1 — "H@1").

Q5.1.3. Ablation bắt buộc

Phải báo cáo 4 cấu hình:

- BM25-only (chỉ keyword_text → top-20 → đo metric).
- kNN-only (chỉ vector embedding → top-20 → đo metric).
- Hybrid + RRF (BM25 + kNN, RRF score-ranker pipeline → top-20).
- Hybrid + RRF + Reranker (full pipeline theo Technical Proposal: BM25 + kNN + RRF → top-20 → bge-reranker → top-5).

Có thể thêm cấu hình thứ 5 cho hoàn chỉnh: Full + LLM final answer (top-5 → Qwen3-8B → top-1).

Q5.1.4. "Headline metric"

Metric quan trọng nhất phải highlight: Hit@1 (Top-1 accuracy) — vừa là metric clinically relevant nhất ("liệu LLM có đoán đúng bệnh ngay lần đầu"), vừa là metric mà GPT-RagAD nêu trong abstract: "40.6% Hit@1... on the Symptom2Disease benchmark" (Liu et al., 2025, Abstract, p. 1). Đây là số liệu duy nhất từ Abstract của paper mà team có thể đặt số của mình bên cạnh để "đối thoại".

Q5.1.5. Số liệu reference từ GPT-RagAD (áp dụng Quantitative-Results Rule)

Các số liệu sau được trích nguyên văn từ paper GPT-RagAD (Liu et al., 2025) với đầy đủ table/section. Đây là REFERENCE POINT, KHÔNG phải one-to-one baseline.

Metric (Symptom2Disease, GPT-RagAD)	Giá trị nguyên văn + nguồn chính xác
Hit@1 — Vanilla GPT-4o	0.3840 (Table 1, p. 7)
Hit@1 — CoT GPT-4o	0.3991 (Table 1, p. 7)
Hit@1 — Auto-CoT GPT-4o	0.4064 (Table 1, p. 7) — "headline" số trong Abstract ("40.6% Hit@1", p. 1)
Hit@1 — Auto-CoT LLaMA3	0.2971 (Table 1, p. 7)
Hit@1 — Auto-CoT GPT-3.5	0.2824 (Table 1, p. 7)
Hit@10 — Auto-CoT GPT-4o	0.7445 (Table 1, p. 7)
NDCG@10 — Auto-CoT GPT-4o	0.5677 (Table 1, p. 7) — "headline" NDCG, được nêu trong Abstract ("56.7% NDCG@10", p. 1; cũng được nhắc lại là 56.8% trong §4.5, p. 7 — có sự chênh nhẹ giữa Abstract và body, ⚠ team nên trích Abstract figure cho headline)

Metric (Symptom2Disease, GPT-RagAD)	Giá trị nguyên văn + nguồn chính xác
Hit@1 — 1st Layer only (KG retrieval, no LLM rerank)	0.0667 (Table 5, p. 12 "2nd Layer" cột tương ứng = 0.4064)
Hit@10 — 1st Layer only	0.3767 (Table 5, p. 12)
NDCG@10 — 1st Layer only	0.1954 (Table 5, p. 12)
Mức cải thiện do LLM re-rank (Hit@1)	Từ 0.0667 → 0.4064 (Table 5, p. 12); cải thiện ~6× — đây là argument chính cho 2-layer design.
Số sample test	500/1,200 "randomly select 500 samples" (§4.1, p. 6 và Appendix A.1, p. 11)
KG size	1,058 disease (§4.1 và Appendix A.1)
Top-K candidate from layer 1	100 (Appendix A.4, p. 11–12 — "we generate 100 candidate diseases"); ⚠ UNVERIFIED tham chiếu sang code: trong `second_layer_gpt_rerank.py`, hàm `run_LLM` lại slice `row['pred_disease'][0:80]` — sự khác biệt 100 vs 80 không khớp giữa paper và code released.

Q5.1.6. Số liệu reference từ MedRAG

Metric (DDXPlus, MedRAG)	Giá trị nguyên văn + nguồn chính xác
L1 accuracy — MedRAG	88.65 (Table 1, p. 7)
L2 accuracy — MedRAG	83.46 (Table 1, p. 7)
L3 accuracy — MedRAG	68.01 (Table 1, p. 7)
L1 — best baseline (FL-RAG)	90.12 (Table 1, p. 7) — note: FL-RAG L1 thực sự cao hơn MedRAG ở DDXPlus, là "only one exception" mà paper thừa nhận (§6.1, p. 7).
L3 — best baseline (FL-RAG)	66.78 (Table 1, p. 7)
Test subset	30 sample/pathology × 49 pathology = 1,470 test sample (Appendix B.2, p. 11). Train subset (retrieve): 240/pathology × 49 = ~11,760 + test = 13,230 "max balanced sub-dataset" (Appendix B.2).

Nhắc lại quan trọng: Vì kiến trúc, embedding, LLM backbone, và (có thể) subset Symptom2Disease của team đều khác với GPT-RagAD, mọi so sánh số liệu phải được đặt trong context như một REFERENCE POINT, KHÔNG phải like-for-like baseline. Báo cáo phải nói rõ điều này.

Q5.2. Tier 2 — Metric có thể defer (Phase 2)

- **ICD-10 hierarchical near-miss:** Yêu cầu trường `icd10-id` (chỉ có ở DDXPlus, không có ở S2D hay Mayo). Cần thêm việc parse ICD-10 hierarchical structure (chapter > block > category > subcategory). Lý do defer: Design C dùng S2D không có ICD-10 nguyên thủy; phải mapping thủ công 24 S2D label sang ICD-10 → thêm 2–3 person-day.
- **Severity-aware safety metric:** Yêu cầu trường `severity` (Tchango et al., 2022 §3.1, p. 4 — chỉ có ở DDXPlus). Có thể định nghĩa metric vd "missed severe disease ratio" = số ca team đoán nhẹ trong khi ground truth severity ≤ 2. Defer vì S2D không có severity.
- **Multi-turn active questioning (MedRAG-style):** MedRAG có Proactive Diagnostic Questioning Mechanism (Zhao et al., 2025, §4.2.4, p. 6). Triển khai cần discriminability score function và

masking simulation (Zhao et al., 2025, Appendix B.3, p. 11). Defer vì cần architecture extension đáng kể.

- **BERTScore / BLEU / ROUGE trên explanation:** MedRAG báo cáo BERTScore 0.8359, BLEU 0.2189, ROUGE 0.2863, METEOR 0.2822 trên CPDD (Table A1, Appendix E, p. 12). Defer vì S2D không có "reference explanation" để so sánh; muốn dùng phải tự generate reference (đắt thời gian) hoặc dùng LLM-as-judge (cần subjective evaluation framework Mini-CEX hoặc tương đương).
- **Multilingual eval (DX, IMCS21):** GPT-RagAD evaluate trên DX (Chinese, 104 sample) và IMCS21 (Chinese, 500 pneumonia case) — Liu et al., 2025, §4.1, p. 6. Defer vì team đang dùng BGE-small-en-v1.5 chuyên cho English; không phải mục tiêu Phase 1.

Q6. Kế hoạch hành động theo vai trò (Deadline 22–25/06/2026)

Lưu ý: Kế hoạch dưới đây được xây dựng cho RECOMMENDED design (Design C — Mayo KB + Symptom2Disease queries). KHÔNG bao gồm task DDXPlus, vì DDXPlus KHÔNG được dùng trong Phase 1.

Q6.1. Nguyên tắc chung trước Day 1

Mọi thành viên phải **ĐỌC** trước những phần sau (chỉ phần được nêu, không cần đọc cả paper):

- Technical Proposal: §2 (Architecture), §3 (Data Preparation), §6 (Retrieval Strategy), §7 (Reranking), §8 (LLM). Đọc kỹ §3.1 "Three Logical Views of a Document" — đây là điểm khác biệt cốt lõi của thiết kế.
- GPT-RagAD paper (Liu et al., 2025): Abstract (p. 1), §4 Experiment (p. 6–8), Appendix A.1 Datasets (p. 11), Table 1 (p. 7), Table 5 ablation (p. 12).
- HF dataset card celikmus/mayo_clinic_symptoms_and_diseases_v1 — kiểm tra schema.
- Kaggle Symptom2Disease page — kiểm tra schema và xác nhận "no official split".

Q6.2. Phân công chi tiết theo ngày (10–11 ngày làm việc trước deadline)

Day 1 (T-10) — Setup & Data Acquisition

- **Nguyen (AI Engineer – Data):** Download dataset; (1) ``datasets.load_dataset("celikmus/mayo_clinic_symptoms_and_diseases_v1")`` lưu thành parquet/csv; (2) download Symptom2Disease.csv từ Kaggle; (3) commit raw data vào branch ``data/raw`` của repo (giữ file gốc nguyên vẹn). Deliverable: file ``data/raw/mayo.parquet``, ``data/raw/symptom2disease.csv`` + một notebook ``01_data_audit.ipynb`` mô tả số lượng row, distribution per class, độ dài text trung bình.
- **Tri (Tech Lead):** Tạo GitHub repo (private hoặc public theo quyết định team), tạo ``pyproject.toml`` hoặc ``requirements.txt`` với version pin (``opensearch-py==X``, ``sentence-transformers==X``, etc.), thiết lập GitHub Actions cho lint. Đăng ký Aiven OpenSearch free tier, tạo cluster, ghi credentials vào ``.env`` (không commit). Deliverable: repo structure + Aiven cluster sẵn sàng.
- **Thuong (Domain Expert):** Lập bảng mapping 24 S2D label ↔ Mayo disease label (1,058 disease). Quy tắc: ưu tiên exact-match → fuzzy match → manual review. Ghi rõ những label không có trong KB (sẽ đếm là 0 trong Hit@K). Deliverable: file ``mapping/s2d_to_mayo_label_map.csv`` với cột (s2d_label, mayo_label, match_type ∈ {exact, fuzzy, manual, missing}, reviewer_initials).
- **Tu (AI Engineer – Pipeline):** Cài đặt sentence-transformers, test ``SentenceTransformer("BAAI/bge-small-en-v1.5")`` chạy được trên Colab T4. Verify dimension = 384, embedding L2-normalized. Deliverable: notebook ``02_bge_sanity.ipynb`` chứng minh model load + embed một câu mẫu.
- **Huong (QA):** Đọc kỹ Section 5 của Technical Proposal và Table 1 + Table 5 của GPT-RagAD paper. Soạn dự thảo evaluation protocol document: liệt kê Tier 1 metric, cách tính, công thức

MRR và NDCG, công thức RRF với $k=60$ (theo §6.3 Technical Proposal). Deliverable: file `evaluation/protocol.md`.

Day 2 (T-9) — Mayo Symptom Extraction

- **Nguyen:** Viết script `prepare\_mayo\_index.py`. Đầu vào: `data/raw/mayo.parquet`. Xử lý: với mỗi (text, label), trích xuất ra (a) `disease` = label đã clean; (b) `symptoms[]` — danh sách triệu chứng tách ra từ free-text (dùng LLM Qwen3-8B với prompt rút gọn, theo mẫu hàm `prompt\_generation\_mayo` của GPT-RagAD: "Please summarize the symptoms of {disease}..."); (c) `keyword\_text` = ghép disease + symptoms (BM25-friendly); (d) `embed\_text` = symptom-first template theo Technical Proposal §3.2. Output: `data/processed/mayo\_docs.jsonl`. Deliverable: 1,058 doc dạng JSON đầy đủ 4 logical fields.
- **Thuong:** Review 50 sample ngẫu nhiên của `data/processed/mayo\_docs.jsonl` xem trích xuất symptom có hợp lý không (vd "Influenza" phải có fever/cough/fatigue). Đánh dấu các case lỗi để Nguyen sửa prompt. Deliverable: file `mapping/review\_50.csv` với cột (idx, disease, symptoms_extracted, reviewer_judgment ∈ {OK, missing, noisy}, comment).
- **Tu:** Thiết lập OpenSearch index mapping theo Technical Proposal §5.2 (gồm `keyword\_text` text field, `embedding` knn_vector 384-dim với `space\_type: cosinesimil`, các metadata field). Test indexing 5 doc giả lập. Deliverable: script `setup\_opensearch\_index.py` và một notebook chứng minh index_mapping đúng.
- **Tri:** Hỗ trợ Tu debug Aiven connection; thiết lập search pipeline `hybrid-rrf` với score-ranker processor (Technical Proposal §6.3). Deliverable: shell snippet PUT `\_search/pipeline/hybrid-rrf` chạy thành công.
- **Huong:** Soạn unit test cho retrieval metric (Hit@K, MRR@K, NDCG@K) — input là một list of predictions, output là số. Verify bằng cách dùng `scipy` hoặc `sklearn` đối chiếu. Deliverable: file `tests/test\_metrics.py` với ≥ 5 test case (gồm edge case: predicted list rỗng, ground truth không có trong top-K).

Day 3 (T-8) — Indexing Mayo (full) + Query preparation

- **Tu:** Embed toàn bộ 1,058 doc với BGE-small + L2 normalize. Index vào OpenSearch. Verify với 1 query thử `GET /diseases/\_search` (chỉ BM25, chỉ kNN, hybrid). Deliverable: index `diseases` chứa đủ 1,058 doc; notebook `03\_indexing.ipynb` xác nhận count = 1058.
- **Nguyen:** Viết script `prepare\_queries.py` xử lý Symptom2Disease.csv: (a) load 1,200 row; (b) apply synonym expansion theo Technical Proposal §3.4 (vd "tired" → "fatigue", "throwing up" → "vomiting" — danh sách synonym tự maintain trong code); (c) stratified split 70/15/15 với seed=42; (d) lưu `data/processed/queries\_train.jsonl`, `queries\_dev.jsonl`, `queries\_test.jsonl`. Deliverable: 3 file split với index column ổn định để reproducible.
- **Thuong:** Hoàn tất bảng mapping S2D ↔ Mayo (từ Day 1) — về tới final version. Verify với Nguyen rằng mọi label trong test split đều có entry trong mapping. Deliverable: `mapping/s2d\_to\_mayo\_label\_map\_v1.csv` (signed-off).
- **Tri:** Setup Qwen3-8B inference endpoint (Hugging Face Inference Endpoints free tier hoặc Colab local + ngrok). Test latency. Deliverable: doc `infra/qwen\_setup.md` mô tả cách invoke Qwen3-8B từ pipeline.
- **Huong:** Soạn dev-set baseline check protocol: với 168 query dev, chạy BM25-only để xác lập "sanity baseline" (kỳ vọng Hit@1 ≥ 0.10 — nếu thấp hơn rõ rệt là pipeline có lỗi). Deliverable: file `evaluation/sanity\_protocol.md`.

Day 4 (T-7) — First end-to-end run trên dev set

- **Tu:** Implement client-side workflow: query → BGE embed → OpenSearch hybrid query với pipeline `hybrid-rrf` → top-20 → bge-reranker-base local → top-5 → format prompt cho Qwen3-8B → LLM trả về top-1 disease. Test trên 168 dev query. Deliverable: script `run\_pipeline.py` + first dev-set result.

- **Huong:** Chạy sanity baseline (BM25-only) trên dev và verify $\text{Hit@1} \geq 0.10$. Nếu < 0.10 , alert team. Deliverable: file ``results/dev_bm25_only_baseline.json``.
- **Nguyen:** Hỗ trợ debug pipeline khi có mismatch label (vd LLM trả về disease không có trong KB). Deliverable: log analysis.
- **Thuong:** Random review 30 dev prediction để đánh giá định tính: có lỗi nào do label-mapping không? Có disease nào hệ thống thường nhầm? Deliverable: file ``analysis/dev_qualitative_review.md``.
- **Tri:** Monitor Aiven cluster utilization (RAM, query latency). Tune query timeout nếu cần.

Day 5 (T-6) — Ablation experiments

- **Tu:** Chạy 4 cấu hình ablation trên dev set: (1) BM25-only, (2) kNN-only, (3) Hybrid + RRF, (4) Hybrid + RRF + Reranker. Lưu kết quả per-query. Deliverable: 4 file JSON kết quả + một bảng tổng hợp dev metric.
- **Huong:** Tính Hit@1 , Hit@5 , Hit@10 , MRR@10 , NDCG@10 cho mỗi cấu hình. Bootstrap CI 1,000 lần resampling. Deliverable: bảng metric với CI95% (vd " $\text{Hit@1} = 0.34 [0.27, 0.41]$ ").
- **Nguyen + Thuong:** Error analysis: lấy 20 query "miss" và 20 query "hit" trên Hybrid+Reranker, phân loại failure modes theo categories của GPT-RagAD (Liu et al., 2025, §5, p. 8: Semantic Overlap, Global Prior Bias, Ambiguous Input, Retrieval Miss). Deliverable: ``analysis/error_taxonomy.md``.
- **Tri:** Code review toàn bộ pipeline; merge các PR vào branch ``main``.

Day 6 (T-5) — Prompt tuning + LLM final answer

- **Tu:** Tune prompt cho Qwen3-8B trên dev set. Base prompt: tham khảo mẫu prompt của GPT-RagAD (gitingest ``second_layer_gpt_rerank.py`` hàm ``prompt_generation``). Thử 2–3 biến thể: vanilla, CoT, structured-output. Deliverable: file ``prompts/qwen_prompts.yaml`` với version tracking.
- **Huong:** Đánh giá mỗi prompt variant trên dev, chọn variant tốt nhất theo Hit@1 final (sau LLM).
- **Thuong:** Manually inspect 30 output của variant tốt nhất; xem LLM có justify hợp lý không, có hallucinate tên bệnh không trong KB không. Deliverable: ``analysis/llm_output_review.md``.

Day 7 (T-4) — Pipeline freeze + Test set preparation

- **Cả team:** Code freeze. Mọi parameter chốt. KHÔNG được chạm vào test set cho đến khi tất cả hyperparameter đã chốt.
- **Tri:** Tag commit ``v1.0-rc1``.
- **Huong:** Soạn file ``evaluation/test_protocol.md`` chi tiết: số lần chạy (1 lần — không retry test set), cách aggregate metric, format kết quả cuối.

Day 8 (T-3) — Final test run

- **Tu:** Chạy 4 cấu hình ablation trên test set (192 sample). Lưu raw output. Deliverable: 4 file ``results/test_<config>.json``.
- **Huong:** Tính Tier 1 metric với CI bootstrap. Deliverable: bảng kết quả final + scripts tạo bảng.
- **Tri + Nguyen + Thuong:** Bắt đầu viết draft báo cáo cuối (Introduction, Method, Results, Discussion). Phân chia: Tri viết Method (architecture, pipeline); Nguyen viết Data section; Thuong viết Discussion (giới hạn, ý nghĩa); Huong viết Evaluation/Results.

Day 9 (T-2) — Báo cáo & visualization

- **Cả team:** Viết draft báo cáo Markdown/LaTeX, tạo bảng kết quả (đặt cạnh số GPT-RagAD), tạo ablation chart. Code freeze, không thay đổi parameter.

Day 10 (T-1) — Review & polish

- **Cả team:** Cross-review báo cáo. Mỗi người review section của người khác. Verify mọi số liệu trong báo cáo khớp với file JSON kết quả. Fix typo, formatting.

Day 11 (Submission day, 22–25/06)

- **Cả team:** Final submission. Tag commit `v1.0-final-submission`. Đóng băng repo (protect main branch).

Q6.3. Deliverable summary

- `data/raw/mayo.parquet`, `data/raw/symptom2disease.csv`.
- `data/processed/mayo\_docs.jsonl` (1,058 doc, 4 logical fields).
- `data/processed/queries\_{train,dev,test}.jsonl` (split với seed=42).
- `mapping/s2d\_to\_mayo\_label\_map\_v1.csv` (signed-off).
- `prepare\_mayo\_index.py`, `prepare\_queries.py`, `setup\_opensearch\_index.py`, `run\_pipeline.py`.
- `results/test\_{bm25,knn,hybrid,hybrid\_reranker}.json` + bảng aggregate với CI95%.
- Báo cáo Markdown/PDF: Introduction, Method, Data, Evaluation, Results, Discussion (limits + reference points to GPT-RagAD).
- README.md cập nhật: cách reproduce kết quả từ raw data → final metric.

Final Self-Check — Mọi claim định lượng có nguồn cụ thể

Mọi số liệu định lượng được trích trong báo cáo này:

Claim định lượng	Nguồn chính xác
GPT-RagAD KB size = 1,058 disease	Liu et al., 2025, §4.1, p. 6 và Appendix A.1, p. 11
GPT-RagAD evaluate trên 500/1,200 sample của S2D	Liu et al., 2025, §4.1, p. 6: "We randomly select 500 samples"
GPT-RagAD Hit@1 Auto-CoT GPT-4o = 0.4064	Table 1, p. 7
GPT-RagAD NDCG@10 Auto-CoT GPT-4o = 0.5677	Table 1, p. 7 (Abstract ghi "56.7%", body ghi 0.5677 = 56.77%)
GPT-RagAD Hit@1 = 0.0667 (1st layer only)	Table 5, p. 12
GPT-RagAD top-K candidate = 100	Appendix A.4, p. 11–12. ⚠️ UNVERIFIED so với code: `second_layer_gpt_rerank.py` slice [0:80]
GPT-RagAD failure rate: 1st-layer recall miss = 12.93%, 2nd-layer rerank error = 19.41%	Table 9, p. 14
GPT-RagAD bucket Hit@1: cough=0.3219,	Table 4, p. 8

Claim định lượng	Nguồn chính xác
diarrhea=0.3342, indigestion=0.3692	
DDXPlus: ~1.3M patient, 49 pathology, 110 symptom, 113 antecedent (=223 evidence)	Tchango et al., 2022: §1, §3.1, Table 1 p. 7
DDXPlus split 80/10/10 stratified	Tchango et al., 2022, §3.4, p. 6
DDXPlus avg 10.07 symptom + 3.49 antecedent / patient	Tchango et al., 2022, Table 2, p. 7
DDXPlus severity 1–5, 1=most severe	Tchango et al., 2022, §3.1, p. 4
MedRAG subset DDXPlus = 13,230 patient (240 train + 30 test per pathology)	Zhao et al., 2025, Appendix B.2, p. 11
MedRAG DDXPlus L1/L2/L3 = 88.65 / 83.46 / 68.01	Zhao et al., 2025, Table 1, p. 7
MedRAG CPDD = 551 patient, 33 diagnosis	Zhao et al., 2025, §5.1, p. 6
MedRAG CPDD split 9:1	Zhao et al., 2025, Appendix B.2, p. 11
MedRAG FL-RAG DDXPlus L1 = 90.12 (best baseline)	Zhao et al., 2025, Table 1, p. 7
MedRAG BERTScore 0.8359, BLEU 0.2189, ROUGE 0.2863, METEOR 0.2822 (CPDD)	Zhao et al., 2025, Table A1, Appendix E, p. 12
S2D dataset = 24 disease × 50 sample = 1,200 datapoint	Barman, n.d. (Kaggle dataset card)
S2D no official split — single CSV	Barman, n.d., Kaggle page

Claim định lượng	Nguồn chính xác
Mayo Clinic celikmus HF: 1.06k rows, 2 columns (text, label), 1 split (train)	HF dataset card https://huggingface.co/datasets/celikmus/mayo_clinic_symptoms_and_diseases_v1
DDXPlus license = CC-BY	Tchango et al., 2022, §3.4, p. 6 + figshare landing page
Aiven free tier: 4 GB RAM, 20 GB storage, single node	Technical Proposal, §5
Hybrid pipeline RRF k=60	Technical Proposal, §6.3 (công thức nguyên văn)
BGE-small-en-v1.5: 384-dim	Technical Proposal, §4 + verified on HF model card BAAI/bge-small-en-v1.5

⚠ UNVERIFIED — phải kiểm tra trước final submission

- License của HF dataset `celikmus/mayo\_clinic\_symptoms\_and\_diseases\_v1` — trang dataset card không hiển thị license tag rõ ràng. Team cần xác nhận license và terms of use, đặc biệt nếu redistribute.
- License của Kaggle dataset `niyarbarman/symptom2disease` — trang Kaggle không hiển thị license rõ ràng tại thời điểm web crawl. Team cần kiểm tra trên Kaggle UI.
- Tính chất "synthetic vs human-written" của Symptom2Disease — Kaggle page không nói rõ. Một số phiên bản phái sinh (vd `gretelai/symptom\_to\_diagnosis`) ghi "adapted using an LLM", nhưng đây là bản phái sinh, KHÔNG phải bản gốc Kaggle. Team không nên khẳng định "semi-synthetic" cho bản gốc.
- LLM backbone GPT-RagAD sử dụng (paper: "LLaMA3, GPT-3.5, GPT-4o" theo §4.4, p. 6; code released: `ChatOpenAI(model="gpt-4")` hard-code trong `first\_layer\_graph\_gen.py` và `second\_layer\_gpt\_rerank.py`). Mismatch giữa paper và code — không được khẳng định chính xác paper dùng GPT-4o vs GPT-4.
- Top-K candidate của GPT-RagAD: paper Appendix A.4 nói "100 candidate"; code `second\_layer\_gpt\_rerank.py` hàm `run\_LLM` lại slice `[0:80]`. Có thể là leftover code từ thử nghiệm trước. Mismatch cần ghi nhận.
- INITIAL_EVIDENCE của DDXPlus — README mila-iqia/ddxplus không nêu rõ cơ chế chọn (KHÔNG có cụm từ "randomly selected" trong description chính thức). Team không được giả định.
- NDCG@10 của Auto-CoT GPT-4o trên S2D — Abstract (p. 1) ghi "56.7%", body §4.5 (p. 7) ghi "56.8%". Sự lệch nhẹ 0.001 — team có thể trích Abstract figure cho headline.

Tham khảo (Harvard style)

- Barman, N. (n.d.). *Symptom2Disease* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/niyarbarman/symptom2disease>
- Liu, X., Sun, D., Fung, Y. R., Hakkani-Tür, D. and Abdelzaher, T. (2025). *GPT-RagAD: Two-layer Retrieval-Augmented Multilingual Diagnosis System*. Proceedings of Machine Learning Research 297 (ML4H 2025). Github: <https://github.com/tracy3057/GPT-RagAD>

- PhysioNet (n.d.). *Use of MIMIC Data with Large Language Models and Online Services*. <https://physionet.org/news/post/llm-responsible-use/> và <https://physionet.org/news/post/gpt-responsible-use/>
- Tchang, A. F., Goel, R., Wen, Z., Martel, J. and Ghosn, J. (2022). *DDXPlus: A New Dataset For Automatic Medical Diagnosis*. NeurIPS 2022 Track on Datasets and Benchmarks. arXiv:2205.09148. Dataset: https://figshare.com/articles/dataset/DDXPlus_Dataset_English_/22687585 ; <https://github.com/mila-iqia/ddxplus>
- Zhao, X., Liu, S., Yang, S.-Y. and Miao, C. (2025). *MedRAG: Enhancing Retrieval-augmented Generation with Knowledge Graph-Elicited Reasoning for Healthcare Copilot*. Proceedings of the ACM Web Conference 2025 (WWW '25). DOI: 10.1145/3696410.3714782. Github: <https://github.com/SNOWTEAM2023/MedRAG>
- celikmus (n.d.). *mayo_clinic_symptoms_and_diseases_v1 [Dataset]*. Hugging Face. https://huggingface.co/datasets/celikmus/mayo_clinic_symptoms_and_diseases_v1